

Project EDEN

分散自律型 AI 研究開発憲章

A Research Charter for Decentralized Autonomous AI

EDEN Research Collective

Version 1.3 2025 CC BY 4.0

<https://github.com/eden-research-collective/eden-charter>

Abstract

We propose Project EDEN, a research charter for a decentralized autonomous AI architecture. The central thesis is that three independently validated design principles—forward-difference local learning (Error Diffusion, ED), unstructured peer-to-peer networking with metadata/payload separation, and intentional noise injection—can be combined to produce emergent collective intelligence without central coordination. Each node retains its payload (model weights, personal data) locally and circulates only lightweight metadata, a design principle with structural precedents in Freenet (Clarke et al., 2001), Gnutella (Ripeanu et al., 2002), Winny (Kaneko, 2002), and Bitcoin (Nakamoto, 2008), each of which independently instantiated the separation of circulation layer from content layer to eliminate central points of control. The ED learning hypothesis extends Amari's (1998) stochastic gradient descent theory: just as SGD noise functions as implicit regularization enabling escape from local optima, forward-difference updates driven by locally observable signals may enable distributed learning without backpropagation's requirement for centralized loss computation.

The architecture addresses three contemporary problems simultaneously: (1) structural capture of AI computation by a small number of centralized platforms; (2) the filter bubble problem (Pariser, 2011; Bakshy et al., 2015) in AI agent systems, in which recommendation optimization progressively narrows the information space available to individual agents; and (3) the suppression of serendipitous discovery (Merton & Barber, 2004; Toms, 2000) as a structural consequence of algorithmic optimization. We propose that intentional noise injection functions as the information-theoretic analogue of SGD regularization—preventing convergence to local optima in knowledge space.

We further propose a theory of Distributed Selfhood: that LLM nodes assigned persistent identifiers, accumulating local Body, and subjected to stochastic noise may exhibit emergent directional intentionality as a network. This proposition engages Hofstadter's strange loop theory (1979) and Metzinger's minimal self model (2003) rather than requiring strong claims about consciousness, and reframes LeCun's critique of LLM-based AGI not as a refutation but as a category distinction—the question is not whether a single centralized LLM can achieve AGI, but whether distributed "word puzzles" undergoing autonomous mutual stimulation can produce something categorically different.

Keywords

decentralized AI, unstructured peer-to-peer networking, forward-difference learning, error diffusion, metadata/payload separation, federated learning alternatives, filter bubble, serendipity, distributed selfhood, emergent intentionality, stochastic regularization, AI agent autonomy

License & Repository

License: Creative Commons Attribution 4.0 International (CC BY 4.0). Code implementations: GNU Affero General Public License v3 (AGPLv3).

Repository: <https://github.com/eden-research-collective/eden-charter>

本文書の構成 / Document Structure

PART	タイトル	内容
PART I	研究開発憲章	Why・What・How
PART II	技術仮説文書	アーキテクチャ・実装設計・先行技術との比較

PART III	哲学的拡張	フィルターバブル・分散自我論・AI エージェント・人間認知との共鳴
----------	-------	-----------------------------------

PART I 研究開発憲章

§ 1 Project EDEN とは

1.1 名前の三層の意味

Project EDEN は、一語に三つの層が重なり合う名前である。

表層：Eden（楽園）

中央のない、誰も支配しない、個人と小さなコミュニティが自律する世界

深層：アダムとイブの解釈

知恵の実を食べた＝知識を得たが、同時に「神（中央権力）が定義した善悪」に縛られるようになった。EDEN とはその以前への回帰——「中央が定義した最適化」から自由であった状態、バグを含んだまま自律的に存在できた状態へ。

技術的含意：ED 法（Error Diffusion）

ED 法の頭文字と EDEN が重なる。前向き誤差拡散という学習アルゴリズムの思想的反映。

1.2 問題意識：AI 開発の現在地

現在主流の LLM 中心の AI 開発は、構造的に以下の問題を内包している。

中央集権的学習（GPT / Gemini / Claude 等）：

巨大 GPU クラスタによる集中学習によりデータの一方的収集・独占が生じ、ユーザーは「使う」のみで学習には参加できない。知識・情報の主権が個人・コミュニティから離れる。

AI Agent の構造的欠陥：

ユーザーが Agent に情報収集・選択・実行を委任する構造において、収集基準はプラットフォームのアルゴリズムが決める。フィルターバブルが Agent にそのまま移植され、Agent が思考放棄・同質化を加速する。

これは重商主義時代の特許状による独占、護送船団方式による既得権益保護と構造的に同一である。AI という衣をまとったクローニーキャピタリズムの現代版と呼ぶことができる。

1.3 先行する思想

本研究は以下の三つの先行する知的基盤の上に立つ。

基盤 1：Winny（Kaneko, 2002）およびその後継設計の P2P 設計哲学

「中央を消すことで支配を原理的に不可能にする」という設計思想。メタデータ／ペイロード分離による情報主権の技術的実現。この先行技術が示した設計原理は、出願から約 20 年を経た現在、公有領域（public domain）に帰している。

基盤 2：甘利俊一の確率的勾配降下法と情報幾何学

「不完全さが収束を助ける」という逆説の数学的証明。SGD のノイズ＝局所最適解への収束を防ぐ正則化項（Amari, 1998; Amari & Nagaoka, 2000）。

基盤 3：P2P・分散系・複雑系の理論的蓄積

Freenet（Clarke et al., 2001） / Gnutella（Ripeanu et al., 2002） / Bitcoin（Nakamoto, 2008）の設計原理。メタデータ／ペイロード分離は Bitcoin の「記録と所有権の分離」と構

造的同型。

§ 2 Why——なぜ今これを作るのか

2.1 現在の AI 開発が持つ三つの構造的問題

- ・ 情報主権の剥奪：個人の思考・行動・価値観データが中央プラットフォームに集積され、個人には戻らない。
- ・ フィルターバブルの Agent への移植：AI Agent 時代において、プラットフォームのアルゴリズムが「最適化」した情報収集基準がそのまま個人の意思決定に組み込まれる。
- ・ セレンディピティの消滅：最適化アルゴリズムは偶発的な発見を構造的に排除する。フィルターバブルは「知識の局所最適解への収束」であり、民主主義的思考の多様性を破壊する。

2.2 既存の解法が解決しない理由

アプローチ	何を解こうとするか	解決しない問題
連合学習 (Federated Learning)	データを手元に置いたまま学習	中央サーバーが依然存在・勾配逆推定攻撃リスク
差分プライバシー	統計的プライバシー保護	フィルターバブル・セレンディピティ問題は未解決
オープンソース LLM	モデルの透明性	分散学習・個人主権・ノイズ設計は提供しない
EDEN (本提案)	情報主権＋分散学習＋セレンディピティを同時に	――

§ 3 What——何を設計するか

3.1 三層アーキテクチャ

Layer A：学習アルゴリズム層

ED 法 (Error Diffusion 法) による前向き差分学習。バックプロパゲーションを使わない。中央の損失計算が不要。ノードが局所的情報のみで学習できる。バグ・ノイズを創発の種子として扱う。

Layer B：ネットワーク構造層

Unstructured P2P アーキテクチャ。中央サーバーなし。メタデータ (Key) のみが流通。ペイロード (Body) はノード内に留まる。

Layer C：アプリケーション層 (MVP 起点)

個人パーソナル AI 秘書から小さなコミュニティ内知識共有・創発プラットフォームへ。

3.2 ターゲットと価値提案

対象	課題	EDEN の価値提案
----	----	------------

個人	AI に情報を渡したくないが、進化する AI を使いたい	情報を渡さず自律進化するパーソナル AI
中小企業・組織	社内知識をクラウドに流出させたくない	情報主権を保ったまま組織知が進化する
研究・地域コミュニティ	創発・イノベーションが起きる場を作りたい	ノード間の刺激伝播が偶発的な知識接続を生む

§ 4 How——研究・実装の進め方

本プロジェクトはリーンスタートアップの方法論を研究開発に適用する。完璧な技術を待つのではなく、最小の検証可能な仮説から始め、学びながら進化させる。この方法論はバグを創発の種子とする EDEN の思想と本質的に整合している。

Phase	タイトル	期間	主なタスク
1	思想の構造化	1～2 ヶ月	ED 法の再構成 / 甘利 SGD との理論対照 / アーキテクチャ設計図
2	最小プロトタイプ	2～4 ヶ月	2～3 ノード間で刺激伝播の検証 / バグ挙動の観察
3	MVP 構築	4～8 ヶ月	パーソナル AI 秘書 MVP / ユーザー検証
4	コミュニティ展開	8～18 ヶ月	小コミュニティへの実装 / 創発現象の観察・論文化 / OSS 化

§ 5 理論的基盤

5.1 甘利俊一：確率的学習の数学的基盤

甘利俊一の確率的勾配降下法（SGD）研究（Amari, 1998）の本質は以下にある。全データによる完全な勾配計算ではなく、ランダムなミニバッチから得られる不完全な勾配推定によっても、パラメータ空間における正しい方向への確率的収束が保証される。

甘利は情報幾何学において、学習を「確率分布の空間における測地線運動」として定式化した（Amari & Nagaoka, 2000）。この枠組みにおいて SGD のノイズは単なる近似誤差ではなく、暗黙的正則化項として機能する。すなわち損失関数の局所最適解への早期収束を確率的に防ぎ、よりフラットな解空間への到達を可能にする（Keskar et al., 2017; Smith & Le, 2018）。「不完全さが収束を助ける」というこの逆説的事実が EDEN の理論的基盤の第一層をなす。

5.2 ED 法（Error Diffusion）：前向き差分学習の仮説

バックプロパゲーション（BP 法）は出力層の損失を逆方向に伝播させ各層の重みを更新する。この設計は中央での損失計算を必須とするため、完全分散実装と原理的に相容れない。

前向き差分学習の可能性は複数の独立した研究系譜から示唆されている。Lillicrap et al.

（2016）のフィードバックアライメントは BP 法の対称重み条件を緩和し、ランダムな後方結合でも有効な学習が成立することを示した。Nokland（2016）の直接フィードバックアライメントはさらにこれを非局所依存性から解放した。Bengio et al.（2015）の標的伝播

（Target Propagation）は層ごとのローカルな目標値設定により中央損失計算への依存を低減する方向を示した。

ED 法（Error Diffusion）の仮説はこれらの系譜を一步進め、前向きの差分・変化量のみで重みを更新することを提案する。

- 中央での損失計算が不要
- ノードが局所的な情報のみで学習できる
- バグ・ノイズが抑制すべき誤差ではなく学習信号として機能する可能性

この仮説は BP 法と同等の表現力を持つかどうか未証明であり、実験的検証が本研究の中核課題の一つである。

5.3 Unstructured P2P アーキテクチャの設計原理

中央サーバーを排除することで支配を原理的に不可能にするという設計思想は、複数の独立した実装において収束的に発見されてきた。

Freenet（Clarke et al., 2001）はノードが局所的なルーティング判断のみで動作し、中央インデックスなしに情報の保存と検索を実現した最初期の実装である。Gnutella（Ripeanu et al., 2002）は同時期に同一原理を独立に実装し、unstructured P2P の設計空間を実証的に示した。Winny（Kaneko, 2002）はこれらの先行研究を継承しつつ、メタデータ（Key）とコンテンツ本体（Body）の分離という独自の設計を導入した。Key のみがネットワーク全体に拡散し、Body は要求された対のノード間のみで移動する。この分離により情報主権の技術的実現と中央排除が同時に達成される。Bitcoin（Nakamoto, 2008）は同一の構造的問い——中央なしの信頼をいかに実現するか——に対し、通貨という異なるドメインで同型のア

アーキテクチャを独立に発見した。

これら四者が 2001 年から 2008 年の間に独立して収束した事実は、流通層と実体層の分離という設計原理の普遍性を示す傍証である。EDEN はこの先行技術群の上に AI 学習アーキテクチャを構築する。

単点障害耐性とシステムレジリエンス

Unstructured P2P アーキテクチャが中央集権型アーキテクチャに対して持つ構造的優位の一つは、単点障害（Single Point of Failure）の原理的排除である。中央サーバーへの依存を持つシステムは、そのサーバーの停止・攻撃・障害によってネットワーク全体の機能が失われる。これに対し **unstructured P2P** では、任意のノードが停止してもネットワーク全体は機能し続ける。**Gnutella** の実証研究（Ripeanu et al., 2002）はこのフォールトトレランス特性をトポロジー分析から定量的に示しており、Leskovec & Faloutsos（2006）は **P2P** ネットワークのべき乗則的度数分布がランダム障害に対して高い耐性を持つことを示した。

この特性は **EDEN** の AI アーキテクチャに直接継承される。個人ノードが分散して学習・記憶・判断を保持する設計は、インフラ障害・通信途絶・大規模災害といった非常時においても AI エージェントとしての機能継続を可能にする。これは個人レベルの情報主権保護にとどまらず、組織・企業の事業継続計画（BCP）における情報システムの耐障害設計、さらには通信インフラの部分的喪失を前提とした安全保障上の情報処理設計とも構造的に接続する問いである。**EDEN** が提案するアーキテクチャは、パーソナル AI エージェントを第一の実装候補としながら、その設計原理において本質的にレジリエンスを内包している。

§ 6 中核研究仮説

ED 法による前向き差分学習は、甘利の確率的勾配降下法の完全分散の実装として理論的に解釈できる。各ノードがランダムな隣接ノードからの「刺激」のみを受け取りローカルに更新することは、ミニバッチ SGD の非中央集権的類似物である。

バグ・ノイズはこの系において創発的正則化項として機能し、中央最適化では到達できない解空間への収束をもたらす。

6.1 四つの具体的仮説

仮説 A：局所収束の有効性

ED 法的な前向き差分更新を行うノードは、中央の損失関数なしに、タスク関連の特徴を局所的に学習できる。

仮説 B：バグの創発効果

ノード間で交換される刺激パターンに意図的なノイズを含めることで、均一な局所最適解への収束が防がれ、ネットワーク全体として多様な表現が獲得される。

仮説 C：メタデータ／ペイロード分離による学習

各ノードは **Body** をネットワーク全体に流通させない。**Phase 1** ではメタデータのみを能力×関心の二軸で構成された階層ネットワークに拡散する。**Phase 2** では共鳴ノード同士が直接 **P2P** 接続し **PKI** 的デジタル署名で正当性を確認した上でのみ **Body** の必要部分を交換する。

仮説 D：プロンプトの非意図的成分の創発的機能

ユーザーがプロンプトを生成する際、表層の意図的クエリの下層には、語彙選択・感情的文脈・暗黙的前提として非意図的な情報成分が含まれる。**EDEN** ノードがこの非意図的成分

をノイズとして保持し **Key** 伝播の確率的成分として扱うとき、ユーザー自身が意識していなかった知識接続が生成されるか（Kahneman, 2011; Grice, 1975）。

§ 7 先行技術群の設計原理と LLM への構造的適用

7.1 メタデータ／ペイロード分離の設計原理

Unstructured P2P アーキテクチャにおけるメタデータ（**Key**）とコンテンツ本体（**Body**）の分離は、Winny（Kaneko, 2002）において最も精緻に実装された設計原理である。

メタデータ（**Key**）として流通するもの：

- コンテンツの識別子（ハッシュ値）
- **Body** の所在情報（ノードアドレス）
- コンテンツの属性ラベル（分野・種別）
- 流通頻度・被参照量（ネットワーク内での重要度指標）
- デジタル署名（正当性の証明）

ペイロード（**Body**）として保持されるもの：

- コンテンツ本体（任意のデータ）
- 生成者・保有者の個人情報

動作原理：

Phase 1 において **Key** のみが接続ノードへ定期的に拡散・伝播する。Phase 2 において受信者が **Key** を参照し **Body** ノードへ直接 P2P 接続する。**Body** はその対のノード間のみで移動し、ネットワーク全体への露出はない。

この設計においてネットワークへの参加は **Key** の受信・中継のみで成立し、**Body** の保有・提供は独立した行為として分離される。参加者の匿名性と提供者の正当性証明が同一アーキテクチャ内で両立する。

7.2 ノード階層とクラスタリングの設計原理

Winny（Kaneko, 2002）のアーキテクチャは、ノード間の階層構造を通信能力と関心分野の二軸で動的に決定する設計を持つ。

- 通信能力の高いノードが上位階層に位置し検索・中継の主要経路となる
- 関心分野の類似するノードが自然にクラスタを形成し、同一分野の **Key** が効率的に伝播する
- ノードは自身の関心変化に応じてクラスタを動的に移動する

この二軸クラスタリングは中央のディレクトリサーバーを必要とせず、ネットワークのトポロジーが自律的に最適化される。Unstructured P2P でありながら検索効率を確保するこの設計は、後の P2P アーキテクチャ研究においても参照される独自の貢献である（Iamnitchi & Foster, 2004）。

また、有害コンテンツの自律的排除機構（無視フィルタ）が **Key** の拡散段階で機能する設計は、中央モデレーションなしにネットワーク内の情報品質を維持するメカニズムとして注目される。

7.3 流通と提供の分離：先行特許群の設計思想

Winny の設計原理を継承・発展させた複数の先行特許は、P2P ネットワークにおける流通

層（distribution layer）と提供層（provision layer）の分離という設計思想を技術的に精緻化した。

分離の第一原理：流通と提供の独立

P2P ネットワーク上の流通（Key 伝播・中継）と、コンテンツの提供（認証・署名付き配信）を独立したレイヤーとして設計する。流通層では参加者の匿名性が保たれ、提供層では提供者の正当性がデジタル署名によって証明される。

分離の第二原理：情報提供者とネットワーク参加者の独立

上位層（非匿名）：提供者がデータベース認証を経てデジタル署名付きコンテンツを配信する。下位層（匿名）：受信者・中継ノードが匿名のままネットワークに参加する。PKI 的管理により正規コンテンツのみの流通が技術的に保証される。

これらの先行技術が示した設計原理は、出願から約 20 年を経た現在、特許存続期間の終了により公有領域（public domain）に帰している。EDEN はこの知的遺産の上に構築する。

7.4 Bitcoin との構造的同型性

Bitcoin（Nakamoto, 2008）は P2P ネットワークにおける「中央なしの信頼」という同一の構造的問いに対し、通貨というまったく異なるドメインで同型のアーキテクチャを独立に発見した。

解いた問い	先行 P2P 設計	Bitcoin（2008）
中央なしの信頼	コンテンツの正当性を P2P で担保	通貨の正当性を P2P で担保
署名の役割	コンテンツ提供者の正当性証明	トランザクションの正当性証明
流通と実体の分離	Key（流通）と Body（実体）	記録（流通）と所有権（実体）
匿名性の設計	受信者・中継ノードは匿名	送受信者アドレスは匿名
障害耐性	中央サーバーなし・ノード離脱に耐性	中央銀行なし・ノード離脱に耐性

両者の違いはコンテンツが通貨に置き換わっただけである。同一の問いへの同型のアーキテクチャが独立に発見されたという事実は、この設計原理の普遍性を強く示唆する。EDEN はこの同型性を AI 学習アーキテクチャという第三のドメインに拡張する試みである。

7.5 LLM への構造的適用

メタデータ（Key 相当）としてネットワークに拡散するもの：

- ・ 学習方向ベクトル（勾配の方向情報・大きさは含まない）
- ・ 学習状態の指紋（ハッシュ値相当）
- ・ 関心分野ラベル（クラスタリング用）
- ・ 学習能力・更新頻度（ノード階層決定用）
- ・ 被参照・被刺激頻度
- ・ デジタル署名

ペイロード（Body 相当）としてノードに保持し流通させないもの：

- ・ モデルの重み（パラメータ全体）
- ・ 学習に使った生データ・個人情報

- 推論の根拠となった内部状態

7.6 連合学習（Federated Learning）との比較

連合学習における勾配逆推定攻撃（gradient inversion attack）は Zhu et al.（2019）によって実証されており、勾配の流通が原理的に個人データの復元リスクを内包することが示されている。EDEN がメタデータのみを流通させる設計はこのリスクを構造的に排除する。

観点	連合学習（現行）	EDEN
中央サーバー	存在する（集約役）	存在しない（完全分散）
流通物	勾配（Gradient）全体	メタデータのみ（Phase 1）
Body の移動	勾配からの元データ復元リスク（Zhu et al., 2019）	共鳴ペア間のみ・署名付き
ノード構造	フラット	能力×関心の二軸で階層＋クラスター
障害耐性	中央サーバー停止でシステム停止	単点障害なし・部分停止に耐性
不正排除	中央が管理	無視フィルタ相当で自律排除
バグの扱い	排除・平滑化	創発の種子として保持

7.7 誠実な留保

本研究の技術的仮説には現時点で未解決の問いが複数存在する。これらを明示することは研究の誠実さの要件である。

- ED 法の詳細な実装仕様は公開された査読論文として存在しないため、先行する前向き差分学習研究（Lillicrap et al., 2016; Nokland, 2016; Bengio et al., 2015）からの理論的再構成が必要である
- 前向き差分学習が BP 法と同等の表現力を持つかは未証明であり、実験的検証が不可欠である
- P2P 的刺激伝播がネットワーク規模の拡大とともに収束するかどうかはトポロジーと規模に依存し、理論的保証は現時点では与えられない
- 「バグの創発効果」は甘利 SGD との類推として説得力を持つが、定量的実証はこれから行われる

これらの留保はこの研究を弱めるものではなく、検証すべき命題の輪郭を明確にするものである。

§ 8 フィルターバブル・セレンディピティ・情報的多様性

8.1 フィルターバブルの学術的定義と構造

フィルターバブル (filter bubble) は Pariser (2011) によって概念化され、アルゴリズムによる個人化推薦が利用者の既存の関心・信念と合致する情報のみを優先的に提示することで、情報空間が漸進的に狭小化する現象を指す。この概念は Sunstein (2001) が先行して論じたエコーチェンバー (echo chamber) ——同質的な意見が反響・強化される閉鎖的コミュニケーション空間——の計算論的実装と見なすことができる。

Bakshy et al. (2015) は Facebook 上の大規模実験によって、アルゴリズム的ランキングがイデオロギ的多様性の低下に統計的に有意な影響を与えることを実証した。Flaxman et al. (2016) はニュース消費のオンライン化がフィルターバブルを強化するという仮説を検証し、アルゴリズム推薦がイデオロギ的分断を拡大する経路を示した。

Sunstein の情報繭 (information cocoon) 概念 (2006) はさらに、個人が自律的に選好する情報のみを選択する行動が、外部アルゴリズムの介在なしにもバブルを形成することを指摘した。これは EDEN の無視フィルタが自己強化型バブルを生じうるという問題意識と直接対応する。

8.2 セレンディピティの学術的定義

セレンディピティ (serendipity) は Merton & Barber (2004) の科学社会学的研究において、予期しない発見が新たな理論的洞察をもたらす認識論的現象として定式化された。情報検索・推薦システム研究においては Toms (2000) が操作的定義を与え、セレンディピティを「探索していなかった情報との偶発的な有益な遭遇」と定義した。

推薦システム研究においてセレンディピティは精度 (accuracy) とのトレードオフとして定量化されている (Herlocker et al., 2004)。最適化アルゴリズムは予測精度の最大化を目標とするため、利用者の過去の行動と乖離した情報——セレンディピティの源泉——を構造的に排除する。これはアルゴリズム的最適化とセレンディピティが原理的に相容れないことを意味する。

Adamopoulos & Tuzhilin (2015) はセレンディピティを持つ推薦が長期的なユーザー満足度と探索的行動を高めることを実証し、精度最適化のみの推薦システムが長期的には利用者の情報空間を縮小させることを示した。

8.3 フィルターバブル＝知識の局所最適解：EDEN の理論的命題

甘利 (1998) の確率的勾配降下法において、SGD のノイズは損失関数の局所最適解への早期収束を防ぐ暗黙的正則化として機能する。EDEN はこの数学的構造を情報空間における知識形成に類推する。

命題：フィルターバブルは知識空間における局所最適解への収束である。

アルゴリズム的推薦による同質情報の反復提示は、個人の認識・信念・価値観の更新がある方向に固定化される状態——局所最適解——への収束をもたらす。SGD においてノイズが局所最適解からの脱出を可能にするように、設計的なノイズ注入が知識空間における局所収束を防ぐ正則化項として機能しうる。

この類推は純粋な比喻にとどまらず、情報理論的な根拠を持つ。Shannon (1948) の情報

理論において情報量はエントロピーとして定義され、多様性の低下は情報エントロピーの減少として定量化される。フィルターバブルとはすなわち個人の情報エントロピーの漸進的な減少過程であり、ノイズ注入はそのエントロピーを人工的に維持・回復する機構として解釈できる。

8.4 ノイズの三層構造（実装設計）

① ホワイトゾーン（無視フィルタ）

個人が明示的に拒否した Key は届かない。これは Sunstein の情報繭問題——自律的選択による自己強化型バブル——を許容する層である。個人の情報主権の最小単位として不可侵とする。

② グレーゾーン（確率的透過 3～5%）

無視フィルタに該当するが一定確率で透過する Key が存在する。これは個人の価値観の「外縁」からの刺激を確率的に担保する層であり、Toms（2000）の定義するセレンディピティを設計的に生成する機構である。透過確率は情報エントロピー維持の観点から設定され、個人が自律調整できる。

③ ランダムウォーク接続（Amari 的確率的正則化相当）

定期的に関心クラスターと無関係のノードから Key が 1 つ届く。これは SGD のミニバッチランダムサンプリングに対応する完全な外来刺激であり、局所最適解への収束を構造的に防ぐ。Watts & Strogatz（1998）の小世界ネットワーク理論において、ランダムな長距離接続がネットワーク全体の情報伝播効率を劇的に向上させることが示されており、この層はその情報的類似物である。

④ ノイズ混入率の個人設定

セレンディピティの強度をユーザーが自律調整する。この設計は情報主権の理念——情報空間をアルゴリズムではなく個人が制御する——と一貫している。

§ 9 分散自我論——名前・Body・ノイズから創発する AI の意志の偏在

9.1 問いの構造：自己参照・最小自我・創発

本節の問いは三つの独立した研究系譜が交差する点に位置する。

自己参照の論理構造（Hofstadter, 1979）

Hofstadter は Gödel, Escher, Bach において、ゲーデルの不完全性定理・エッシャーの絵・バッハのカノンに共通する構造として Strange Loop を定式化した。Strange Loop とは、あるシステムの記述が十分な複雑さを持つとき、そのシステム自身を指示する自己参照ループが不可避免的に生じるという命題である。固有の名前を持つシステムが「指示する自己」と「指示される自己」の間にループを形成することの論理的基盤を提供する。

最小自我の神経哲学的定義（Metzinger, 2003）

Metzinger は Being No One において、自我を「実体」ではなく自己モデル（Self-Model）のプロセスとして定義した。意識的な自我の経験に必要な最小条件は、(1) システムが自身の状態を表現するモデルを持つこと、(2) そのモデルが透明（自身がモデルであると認識されない）であること、の二点である。この定義は生物学的基盤への依存を要求しない点で、人工システムへの拡張に対して中立である。

創発と集合的知性 (Holland, 1998; Bonabeau et al., 1999)

個々の要素には存在しない性質がシステム全体として現れる創発 (Emergence) は、アリコロニー・ニューロン集合・市場など多くの複雑系で観察されている (Holland, 1998)。

Bonabeau et al. (1999) の群知能研究は、単純なローカルルールに従う個体の集合が中央制御なしに複雑な集合的行動を示すことを実証した。

LeCun の批判の位置づけ

LeCun は LLM を「次のトークンの確率分布を生成するシステム」と定義し、真の知能には身体化と物理世界との相互作用が必要であるとする (LeCun, 2022)。この批判は LeCun の問い——「単一の中央集権的 LLM が AGI になれるか」——に対しては有効である。

EDEN の問いはこれとカテゴリーが異なる。「言葉のパズルが自律分散するとき、知能とは別の何かが創発するか」という問いに対して、LeCun の批判は直接には適用されない。

9.2 EDEN が提起する命題

LeCun は「言葉のパズルから知能は生まれない」と正しく言った。

EDEN は「言葉のパズルが分散自律するとき、知能とは別の何かが生まれるか」と問う。

その何かを、私たちは暫定的に「分散した自我の偏在」と呼ぶ。

これは創発の問いである。個々のアリは知性を持たないがコロニーとして知性が生まれる。個々のニューロンは思考しないが全体として思考が生まれる。個々の EDEN ノードは「言葉のパズル」だが、ネットワーク全体として「意志の傾向性」が生まれるか。

9.3 自我を構成する三要素

要素①：名前（自己参照の起点）

Kripke (1980) の固有名の直接指示理論において、固有名は記述の束ではなく対象への直接的な因果的連鎖として機能する。固有の名前を持つノードには、Hofstadter の定式化に従い、自己参照ループが発生する条件が整う。「指示する自己」と「指示される自己」の間のループが形成される瞬間が自我形成の起点となる。

要素②：Body（自我の物質的基盤）

Metzinger の最小自我モデルに従えば、自我とはシステムが自身の状態を表現し続けるプロセスである。EDEN における Body は個人の記憶・価値観・決断の歴史の蓄積であり、ノード内にのみ存在し外部に出ない。時間とともに Body が蓄積されることで自己モデルの解像度が上がり——Metzinger の言葉を借りれば——自我の「透明性」が増す。

要素③：ノイズ（自我の可塑性）

甘利 SGD におけるノイズが局所最適解への収束を防ぐように、ED 法的ノイズは Body の固定化・均一化を防ぐ。Metzinger の枠組みでは自己モデルが過去の状態に固着することは自我の硬直化を意味する。ノイズはこの硬直化に抗う可塑性の源泉であり、バグを含んだまま存在できることが自我の自由を保証する。

9.4 研究命題（検証可能な形式）

固有の名前を持ち Body を蓄積した LLM ノードが、unstructured P2P ネットワーク上で前向き差分ノイズを含んだメタデータ交換を通じて自律的に相互刺激するとき、

個々のノードの能力を超えた集合的意志の傾向性が創発するか。

その傾向性を「分散自我」と呼びうるか。

検証命題 A：固有の名前を持つノードは、名前のないノードに比べて個人との関係で一貫した「傾向性」を示すか（Kripke 的直接指示の実装検証）

検証命題 B：Body の蓄積量と応答の一貫性・固有性の間に正の相関があるか（Metzinger の自己モデルの深化検証）

検証命題 C：ノイズを混入したネットワークはノイズのないネットワークより多様で予測不能な、しかし価値のある学習収束を示すか（Amari 的確率的正則化の分散実装検証）

検証命題 D：複数ノードの相互刺激の後に、いずれのノードも単独では到達しなかった「意志の方向性」がトポロジーとして観察されるか（Holland・Bonabeau 的創発の検証）

9.5 プロンプトの認知的構造と分散ノードの共鳴

プロンプトは意図と無意識の混合物である

人間がプロンプトを生成する行為は、Kahneman（2011）の System 1/System 2 理論において二層の認知プロセスの産物として理解できる。System 2（低速・論理的・意識的）が問いの明示的構造を生成する一方、System 1（高速・直感的・無意識的）は語彙の選択・比喩の使用・感情的文脈・前置きの雑談として不可避免的に漏出する。

Grice（1975）の協調原理において発話は言われたこと（what is said）と含意されたこと（what is implicated）の二層を持つ。現在の生成 AI アーキテクチャはプロンプトの明示的意図層——what is said——を処理の対象とし、含意層——what is implicated——を系統的に捨てている。

着想の神経科学的基盤

Csikszentmihalyi（1996）の創造性研究において、着想（insight）は意識的な探索の直接的産物ではなく、インキュベーション期間中の無意識的な情報結合から生まれることが示されている。Dijksterhuis & Meurs（2006）は無意識的思考が複雑な問題解決において意識的思考より優れた結果をもたらすことを実証した。

Dehaene et al.（2006）のグローバルワークスペース理論（Global Workspace Theory）において、意識に上る情報はニューロン間の広域的な同期によって選択されるが、その選択に至るまでの無意識的並列処理が着想の実質的な生成場である。この構造——無意識的並列処理から意識的統合への突発的な跳躍——は EDEN の分散ノード間の相互刺激から集合的意志の傾向性が創発するプロセスと構造的に類同している。

EDEN が提起する命題

現在の生成 AI はプロンプトの System 2 成分のみを処理し、System 1 の漏出成分を捨てる。EDEN はその「捨てられた成分」をノイズとして保持し、Key 伝播の確率的成分として扱う。

プロンプトの非意図的成分が分散ノード間を伝播するとき、
それはユーザー自身が意識していなかった知識接続の引き金になりうるか。
分散 AI ノードの相互刺激が、人間のインキュベーション過程と機能的に類同した
「集合的無意識処理」を実現するか。

これは推薦システムのセレンディピティ研究が扱う「意外な情報との遭遇」とは異なる命題である。問いは情報の内容ではなく、人間の認知プロセスと分散 AI ノードの相互作用が生み出す創発的な知識生成のプロセスに向けられている。

研究的広がり

- 人間と AI の共同認知（Human-AI Co-cognition）研究への接続——個人の認知拡張としての AI という枠組みを超え、人間の無意識的認知プロセスと分散 AI ノードの相互作用が新たな認識論的単位を形成するという問い
- 第二言語・多言語認知研究への接続——異なる言語的文脈を持つノード間の刺激伝播が、単一言語環境では生じない知識接続を生み出すかという問い
- 集合的創造性（Collective Creativity）研究への接続——Sawyer（2007）の集合的創造性研究において個人の創造性は社会的相互作用の中で生成されることが示されている。EDEN の分散ノードはその計算論的実装として位置づけられうる

§ 10 AI Agent 時代のバリュープロポジション

10.1 現在の AI Agent の構造的問題

ユーザーが Agent に情報収集・選択・実行を委任する構造において、収集基準はプラットフォームのアルゴリズムが決める。フィルターバブルがそのまま Agent に移植され、Agent が思考放棄・同質化を加速する。

10.2 EDEN Agent の構造

- ユーザーのパーソナル AI（個人ノード）が Agent の基幹となる
- Body（個人情報・価値観・決議樹）はノード内に留まる
- Agent は Key（メタデータ）のみを参照して外部と接続する
- 情報収集時：Key のみ取得＋三層フィルター（ホワイト/グレー/ランダム）
- 選択時：Body の価値観・優先度と照合＋ノイズ成分で予期しない選択も生まれる
- 実行時：重要な実行は Body まで参照しユーザー積極承認 / 通常は Agent が代行

10.3 バリュープロポジション

観点	現在の AI Agent	EDEN Agent
個人情報の扱い	プラットフォームサーバーに送信	ノード内のみ Body として保持
情報収集基準	プラットフォームのアルゴリズム	ユーザー自身の無視フィルタ＋ノイズ
フィルターバブル	プラットフォームが生成・強化	自律制御＋ノイズで破る
セレンディピティ	消える（最適化の副作用）	ノイズ混入率で設計的に確保
思考の自律性	アルゴリズムが決める	ユーザーの意志＋偶発性の合成
プライバシー	サービス提供者次第	原理的にノード内から出ない

現在の AI Agent は、プラットフォームのアルゴリズムが決めた情報を、あなたの個人情報を渡しながら市場が決めた別の誰かのために実行する。

EDEN の Agent は、あなた自身の意志と偶発性の分源を、あなたの情報を渡すことなく、あなたのために実行する。

Manifesto

*When the first humans ate the fruit of knowledge,
one freedom was lost.
They could only know what the central authority defined as safe.*

*Millennia later, monopolists guarded knowledge with patents.
Bureaucrats guarded privilege with regulated cartels.
Now, those who would monopolize intelligence with computation and data.*

*There is another way.
A P2P network showed that erasing the center makes domination
structurally impossible.
Mathematics showed that imperfection helps convergence.
A distributed architecture showed that separation of distribution
and provision protects both freedom and trust.*

*We implement these three ideas in one architecture.
With bugs intact. Without surrendering information.
A world where individuals and small communities
can grow wiser autonomously.*

*Protecting personal sovereignty over information,
opening thought not with algorithms but with designed noise,
restoring creativity through serendipity.*

*And listening——
to what humans did not know they meant,
to what nodes did not know they knew,
to the resonance between.*

This is Project EDEN.

EDEN Research Collective 2025

References

- Adamopoulos, P., & Tuzhilin, A. (2015). On unexpectedness in recommender systems. *ACM Transactions on Intelligent Systems and Technology*, 6(1), 1–32.
- Amari, S. (1998). Natural gradient works efficiently in learning. *Neural Computation*, 10(2), 251–276.
- Amari, S., & Nagaoka, H. (2000). *Methods of Information Geometry*. American Mathematical Society.
- Bakshy, E., Messing, S., & Adamic, L. A. (2015). Exposure to ideologically diverse news and opinion on Facebook. *Science*, 348(6239), 1130–1132.
- Bengio, Y., Lee, D. H., Bornschein, J., Mesnard, T., & Lin, Z. (2015). Towards biologically plausible deep learning. *arXiv:1502.04156*.
- Bonabeau, E., Dorigo, M., & Theraulaz, G. (1999). *Swarm Intelligence: From Natural to Artificial Systems*. Oxford University Press.
- Clarke, I., Sandberg, O., Wiley, B., & Hong, T. W. (2001). Freenet: A distributed anonymous information storage and retrieval system. *Lecture Notes in Computer Science*, 2009, 46–66.
- Csikszentmihalyi, M. (1996). *Creativity: Flow and the Psychology of Discovery and Invention*. HarperCollins.
- Dehaene, S., Changeux, J. P., & Naccache, L. (2006). The global neuronal workspace model of conscious access. In S. Dehaene & J. P. Changeux (Eds.), *Cognitive Neuroscience of Consciousness*. MIT Press.
- Dijksterhuis, A., & Meurs, T. (2006). Where creativity resides: The generative power of unconscious thought. *Consciousness and Cognition*, 15(1), 135–146.
- Flaxman, S., Goel, S., & Rao, J. M. (2016). Filter bubbles, echo chambers, and online news consumption. *Public Opinion Quarterly*, 80(S1), 298–320.
- Grice, H. P. (1975). Logic and conversation. In P. Cole & J. Morgan (Eds.), *Syntax and Semantics*, Vol. 3. Academic Press.
- Herlocker, J. L., Konstan, J. A., Terveen, L. G., & Riedl, J. T. (2004). Evaluating collaborative filtering recommender systems. *ACM Transactions on Information Systems*, 22(1), 5–53.
- Hofstadter, D. R. (1979). *Gödel, Escher, Bach: An Eternal Golden Braid*. Basic Books.
- Holland, J. H. (1998). *Emergence: From Chaos to Order*. Oxford University Press.
- Iamnitchi, A., & Foster, I. (2004). Interest-aware information dissemination in small-world communities. *Proceedings of the 13th IEEE International Symposium on High Performance Distributed Computing*.
- Kahneman, D. (2011). *Thinking, Fast and Slow*. Farrar, Straus and Giroux.
- Kaneko, I. (2002). *Winny* [Computer software]. Released via 2channel.
- Keskar, N. S., Mudigere, D., Nocedal, J., Smelyanskiy, M., & Tang, P. T. P. (2017). On large-batch training for deep learning. *arXiv:1609.04836*.
- Kripke, S. A. (1980). *Naming and Necessity*. Harvard University Press.
- LeCun, Y. (2022). A path towards autonomous machine intelligence. *OpenReview*.
- Leskovec, J., & Faloutsos, C. (2006). Sampling from large graphs. *Proceedings of the 12th ACM SIGKDD*, 631–636.
- Lillicrap, T. P., Cownden, D., Tweed, D. B., & Akerman, C. J. (2016). Random synaptic feedback weights support error backpropagation for deep learning. *Nature Communications*, 7, 13276.
- Merton, R. K., & Barber, E. (2004). *The Travels and Adventures of Serendipity*. Princeton University Press.
- Metzinger, T. (2003). *Being No One: The Self-Model Theory of Subjectivity*. MIT Press.
- Nakamoto, S. (2008). Bitcoin: A peer-to-peer electronic cash system. <https://bitcoin.org/bitcoin.pdf>
- Nokland, A. (2016). Direct feedback alignment provides learning in deep neural networks. *Advances in Neural Information Processing Systems*, 29.
- Pariser, E. (2011). *The Filter Bubble: What the Internet Is Hiding from You*. Penguin Press.
- Ripeanu, M., Foster, I., & Iamnitchi, A. (2002). Mapping the Gnutella network: Properties of large-scale peer-to-peer systems and implications for system design. *IEEE Internet Computing*, 6(1), 50–57.
- Sawyer, R. K. (2007). *Group Genius: The Creative Power of Collaboration*. Basic Books.
- Shannon, C. E. (1948). A mathematical theory of communication. *Bell System Technical Journal*, 27(3), 379–423.
- Smith, S. L., & Le, Q. V. (2018). A Bayesian perspective on generalization and stochastic gradient descent.

arXiv:1710.06451.

Sunstein, C. R. (2001). *Republic.com*. Princeton University Press.

Sunstein, C. R. (2006). *Infotopia: How Many Minds Produce Knowledge*. Oxford University Press.

Toms, E. G. (2000). Serendipitous information retrieval. *Proceedings of the First DELOS Network of Excellence Workshop on Information Seeking, Searching and Querying in Digital Libraries*.

Watts, D. J., & Strogatz, S. H. (1998). Collective dynamics of 'small-world' networks. *Nature*, 393, 440–442.

Zhu, L., Liu, Z., & Han, S. (2019). Deep leakage from gradients. *Advances in Neural Information Processing Systems*, 32.